

# БИНАРНЫЙ ТРАНСЛЯТОР

Баринов Денис  
МФТИ, гр.Б05-931  
2020 г.

# ЦЕЛЬ

Написать бинарный транслятор в x86-64

Для этого необходимо:

- Изучить структуру ELF файла
- Определить минимальный исполняемый вид и реализовать программу на его основе
- Установить соответствие между командами на своём процессоре и x86-64
- Перевести решение двух задач: вычисление корней квадратного уравнения и нахождение факториала числа

# Executable and Linkable Format

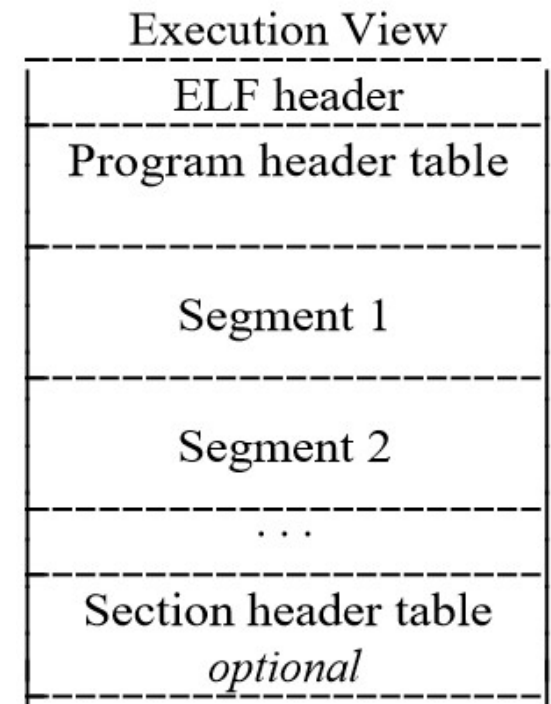
ELF - формат исполняемых (но на самом деле не только) файлов, используемый в Linux (и других, менее популярных системах). Но нас интересует исполняемый.

Структура:

- Elf header (Содержит служебную информацию)
- Section header table (содержит информацию о секциях)
- Sections (.data, .text ...)
- Segments (появляются после линковки)

Но для минимального исполняемого файла нужно:

- Elf header
- Program header
- code (сам код программы)



# ELF HEADER

- 1) **0x7f, 0x45, 0x4c, 0x46** (ELF) – первые 4 байта, следующие 5 байт зависят от аппаратуры, а 7 оставшихся резервные (=0)
- 2) Так как ELF формат подходит для нескольких типов файлов, то надо указать, какой именно. **В нашем случае - 0x02**
- 3) Зависит от архитектуры аппаратной платформы
- 4) **0x01** – номер версии формата (единственно корректный)
- 5) Виртуальный адрес точки входа. (Если такой нет, то 0) Обычно равен  $0x400000 + \text{смещение}$ . **В нашем случае  $0x400000 + \text{sizeof(Elf64_Ehdr)} + \text{sizeof(Elf64_Phdr)}$**  (Про Phdr на сл. слайде)
- 6) Смещение таблицы заголовков программы от начала файла в байтах. (Если такой нет, то 0).  $\text{sizeof(Elf32_Ehdr)}$  или  $\text{sizeof(Elf64_Ehdr)}$

```
# define EI_NIDENT 16
```

```
typedef struct {  
    1 unsigned char    e_ident[EI_NIDENT];  
    2 Elf64_Half       e_type;  
    3 Elf64_Half       e_machine;  
    4 Elf64_Word       e_version;  
    5 Elf64_Addr       e_entry;  
    6 Elf64_Off       e_phoff;  
    7 Elf64_Off       e_shoff;  
    8 Elf64_Word       e_flags;  
    9 Elf64_Half       e_ehsize;  
   10 Elf64_Half       e_phentsize;  
   11 Elf64_Half       e_phnum;  
   12 Elf64_Half       e_shentsize;  
   13 Elf64_Half       e_shnum;  
   14 Elf64_Half       e_shstrndx;  
} Elf64_Ehdr;
```

# ELF HEADER

```
# define EI_NIDENT 16
```

```
typedef struct {  
  1 unsigned char    e_ident[EI_NIDENT];  
  2 Elf64_Half       e_type;  
  3 Elf64_Half       e_machine;  
  4 Elf64_Word       e_version;  
  5 Elf64_Addr       e_entry;  
  6 Elf64_Off        e_phoff;  
  7 Elf64_Off        e_shoff;  
  8 Elf64_Word       e_flags;  
  9 Elf64_Half       e_ehsize;  
10 Elf64_Half       e_phentsize;  
11 Elf64_Half       e_phnum;  
12 Elf64_Half       e_shentsize;  
13 Elf64_Half       e_shnum;  
14 Elf64_Half       e_shstrndx;  
} Elf64_Ehdr;
```

7) Смещение таблицы заголовков секций от начала файла

в байтах. (Если такой нет, то 0) В нашем случае 0, так как нет.

8) Связанные с файлом флаги, зависящие от процессора.

(Если нет, то 0)

9) Размер заголовка файла в байтах (0x34/0x40 для 32/64 bit соотв.)

10) Размер одного заголовка программы (0x20/0x38 для 32/64 bit соотв.)

11) Число заголовков программы. (Если таких нет, то 0)

В нашем случае будет только 1 program header, так что ставим **0x01**

12) Размер одного заголовка секции. (0x28/0x40 для 32/64 bit соотв.)

13) Число заголовков секций **0**, так как у нас нет

14) Индекс записи в таблице заголовков секций **0, =//=**

# PROGRAM HEADER

1) Определяет тип сегмента, на который указывает заголовок.

Их довольно много, поэтому не буду все перечислять, но нас интересует **PT\_LOAD (0x01)** – загружаемый в память сегмент.

2) Флаги для сегмента (заметим, что для 32bit это поле находится в другом месте)

0x01 – разрешение на исполнение,

0x02 – разрешение на запись,

0x04 – разрешение на чтение.

я дал все разрешения, то есть поставил в этом поле **0x07**.

3) Смещение сегмента от начала файла.

4) Виртуальный адрес сегмента в памяти (куда будет загружен)

5) Физический сегмента в памяти (Обычно – **0x400000** (для 4 тоже))

6) Размер сегмента в файле (В нашем случае определяется в самом конце)

7) Размер сегмента в памяти (//=)

8) Выравнивание сегмента. ( $p\_vaddr \% p\_align = p\_offset$ )

```
typedef struct {
    1 Elf64_Word    p_type;
    2 Elf64_Word    p_flags;
    3 Elf64_Off     p_offset;
    4 Elf64_Addr    p_vaddr;
    5 Elf64_Addr    p_paddr;
    6 Elf64_Xword   p_filesz;
    7 Elf64_Xword   p_memsz;
    8 Elf64_Xword   p_align;
} Elf64_Phdr;
```

# Минимальный исполняемый файл

Заполнив две структуры – ELF header и program header, для нашего минимального вида, осталось только написать сам код программы. Для этого положим в начало (сразу после заголовков) Hello world! (сразу отметим, что длина = 12), после чего уже вызовем syscall, предварительно правильно изменив регистры. То есть всё что нам надо сделать – положить в наш выходной файл сразу же после структур вот этот код:

```
'H', 'e', 'l', 'l', 'o', ' ', 'w', 'o', 'r', 'l', 'd', '!',  
0xb8, 0x01, 0, 0, 0,  
0xbf, 0x01, 0, 0, 0,  
0x48, 0xbe, 0x78, 0x00, 0x40, 0x00, 0x00, 0x00, 0x00, 0x00,  
0xba, 0x0c, 0x00, 0x00, 0x00,  
0x0f, 0x05,  
  
0xb8, 0x3c, 0x00, 0x00, 0x00,  
0xbf, 0x00, 0x00, 0x00, 0x00,  
0x0f, 0x05
```

```
// text  
//  
// mov eax, 1  
// mov edi, 1  
// mov rsi, text  
// mov edx, 0x0d  
// syscall  
//  
// mov eax, 0x3c  
// mov edi, 0  
// syscall
```

Здесь всё должно быть понятно, кроме может быть того, какое смещение положить в rsi. Но, в нашем случае, и оно вычисляется очень просто, так как мы кладём сразу же после 2 структур =>  
=> смещение равно  $0x400000 + \text{sizeof}(\text{Elf\_header}) + \text{sizeof}(\text{Program\_header})$  (в зависимости от того, 32 или 64 bit, будет разное смещение. В примере показан случай 64bit)

# Соответствие команд

Разберём, как транслируются команды, на примере push.

В нашем ассемблере было два варианта аргумента push:

PUSH CONST (push 5)

PUSH REGISTER (push ax)

Посмотрим, как устроены эти команды в x86-64:

Здесь мы видим, что номер команды  
меняется в зависимости от аргумента,

6a05	push 5
6650	push ax

чего не было в нашем процессоре. Поэтому мы отдельно  
разбираем случай с числами в качестве аргумента, а для регистров  
замечаем, что opcode меняется следующим образом:

(Точно так же работает и с другими командами)

6650	push ax
6651	push cx
6652	push dx
6653	push bx



# Соответствие команд

Но есть и более сложные команды. Например, команда `sqrt`. Мы понимаем, что вместо одной команды без аргумента нам нужен целый цикл. И, для того чтобы избежать неоправданного роста выходного файла (так как каждый раз будет создаваться цикл), мы отведём в нашем файле место для функций и запишем туда её (также поступим с другими командами, например, `OUT`, которая печатает число). Функции можно оформить в виде отдельных файлов, и вставлять их с помощью `#include` в нужное место массива.

# Соответствие команд

Также особое внимание стоит отвести на константные строки. Для них нам опять же нужно отвести отдельное место в памяти, куда потом будем ссылаться для вывода строк. Например, для функции PRT (которая так раз и выводит константную строку). Так что важно изначально оценить, сколько памяти на что отвести, и сколько будет таких блоков

# Трансляция задач

## квадратное уравнение

При трансляции решения квадратного уравнения возникают небольшие проблемы, такие как:

- Команда SQRT
- Вывод числа (в том числе отрицательного)

Но обе эти проблемы решаются уже описанным образом – создаются функции, которые при появлении этих команд вызываются. А в выводе числа надо просто проверить его знак, и если оно оказалось отрицательным, то взять такое же положительное, а потом в самом начале выводимого числа добавить '-'. (И не забыть увеличить регистр `rdx`, отвечающий за длину выводимого буфера)

# Трансляция задач нахождения факториала числа

Для трансляции этой задачи единственное затруднение может вызвать рекурсия. Так как в нашем процессоре был отдельный стек для адресов возврата (для команды `ret`), а в x86-64 есть только один стек. Но это, опять же, решается выделением памяти. Вместо стека мы просто будем использовать блок памяти и указатель на его конец (эквивалент верхушки стека). Тем самым, всё что нам осталось — реализовать команды `call` и `ret`, но первая из них просто кладёт в “стек” адрес следующей команды и делает `jmp` на нужное место, а команда `ret` делает обратное действие: `jmp` на верхний элемент “стека” и сдвигает указатель на предыдущий.

# Тесты

Квадратное уравнение  
( $ax^2 + bx + c = 0$ )

a b c

1 1 -6

```
-3 2
_2_root
```

0 2 4

```
-2
_1_root
```

0 2 0

```
0
_1_root
```

0 0 0

```
_inf_cnt_of_root
```

0 0 5

```
_no_root
```

Факториал числа  
 $n!$

n

4

```
24
```

5

```
120
```

6

```
720
```

7

```
5040
```

# ВЫВОДЫ

Мы изучили устройство ELF файла и определили его минимальный формат.

Написали перевод команд в x86-64

Перевели решение квадратного уравнения и нахождения факториала числа (с тестами)